

Sistemas Multiagente na Saúde

— 1

¹ Universidade do Minho

Abstract. A crescente complexidade dos sistemas de saúde modernos exige soluções inteligentes, adaptativas e descentralizadas, capazes de coordenar atores e recursos heterogêneos em tempo real. Os Sistemas Multiagente (SMA) têm emergido como um paradigma promissor para responder a estes desafios, oferecendo arquiteturas autônomas, flexíveis e interoperáveis. Este artigo apresenta uma revisão do estado da arte das aplicações de SMA na saúde, com foco particular nas arquiteturas multiagente e nos métodos de comunicação entre agentes utilizados em trabalhos recentes (2019–2024). São analisadas aplicações em domínios como triagem clínica, gestão de recursos hospitalares, monitorização de doentes e suporte à decisão clínica, discutindo a evolução das abordagens — desde arquiteturas BDI tradicionais até à emergência de agentes baseados em *Large Language Models* (LLMs). A revisão revela que os SMA permitem uma coordenação dinâmica e uma maior capacidade de resposta em cenários críticos, embora desafios como interoperabilidade, escalabilidade e validação no mundo real permaneçam em aberto. Conclui-se identificando tendências futuras e oportunidades de investigação neste domínio.

Keywords: Sistemas Multiagente · Saúde · Gestão Hospitalar

1 Introdução

Os sistemas de saúde caracterizam-se por uma complexidade intrínseca, envolvendo um elevado número de atores heterogêneos — doentes, médicos, enfermeiros, pessoal administrativo — bem como recursos físicos como camas hospitalares, equipamentos médicos e blocos operatórios. Coordenar estas entidades num ambiente dinâmico e crítico em termos de tempo coloca desafios significativos que os sistemas de informação centralizados tradicionais frequentemente não conseguem resolver de forma adequada.

A crescente digitalização dos serviços de saúde, aliada ao aumento da esperança média de vida e à pressão sobre os recursos hospitalares, torna ainda mais urgente o desenvolvimento de soluções computacionais inteligentes, adaptativas e descentralizadas.

Os Sistemas Multiagente (SMA) oferecem um paradigma relevante para enfrentar estes desafios. Ao decompor um sistema complexo num conjunto de agentes autônomos e interagentes, cada um com os seus próprios objetivos e conhecimento, os SMA permitem alcançar uma coordenação flexível, robusta e escalável. Na área da saúde, isto traduz-se em sistemas capazes de responder a eventos imprevisíveis, alocar recursos de forma eficiente e apoiar a tomada de

decisão clínica em tempo real. Ao contrário das abordagens centralizadas, os SMA mantêm a sua capacidade operacional mesmo perante falhas parciais, o que os torna particularmente adequados a ambientes críticos como urgências hospitalares e unidades de cuidados intensivos.

Este artigo apresenta uma revisão do estado da arte das aplicações de SMA na saúde. O restante trabalho está organizado da seguinte forma: a Secção 2 fornece enquadramento sobre o domínio da saúde; a Secção 3 analisa os trabalhos identificados na literatura recente, organizados por domínio de aplicação, incluindo uma análise dedicada a arquiteturas e protocolos de comunicação; a Secção 4 oferece uma análise crítica e comparativa; a Secção 5 discute tendências futuras; a Secção 6 descreve a proposta de implementação; e a Secção 7 conclui o artigo.

2 Domínio de Investigação

O domínio da saúde constitui um dos ambientes mais exigentes e complexos para a aplicação de tecnologias computacionais. Os sistemas hospitalares e de cuidados de saúde caracterizam-se por uma elevada diversidade de envolvidos — incluindo doentes, médicos, enfermeiros, técnicos e gestores —, cada um com objetivos, competências e responsabilidades distintas. Estes atores interagem num ambiente profundamente dinâmico, onde o estado do sistema muda continuamente em resposta a novos internamentos, altas, emergências e variações nos recursos disponíveis.

2.1 Pressão Demográfica e Escassez de Recursos

A pressão sobre os sistemas de saúde europeus é crescente e estrutural. Segundo o relatório *Health at a Glance: Europe 2024* da OCDE [1], a esperança média de vida na UE atingiu 81,5 anos em 2023, ao mesmo tempo que se projeta que a proporção de pessoas com 65 ou mais anos suba dos 21% atuais para 29% em 2050. Este envelhecimento populacional traduz-se num aumento contínuo da procura de cuidados, em particular para doenças crónicas e condições complexas que requerem coordenação entre múltiplas especialidades.

Simultaneamente, os sistemas de saúde enfrentam uma crise de recursos humanos sem precedentes. Em 2022 e 2023, vinte países da UE reportaram escassez de médicos e quinze reportaram escassez de enfermeiros, resultando num défice estimado de 1,2 milhões de profissionais face aos limiares mínimos para cobertura universal de saúde [1]. Mais de um terço dos médicos e um quarto dos enfermeiros na UE têm mais de 55 anos e deverão reformar-se nos próximos anos, agravando uma situação já crítica. Do lado da infraestrutura física, a UE dispunha de 2,3 milhões de camas hospitalares em 2022, das quais três quartos são dedicadas a cuidados curativos — uma capacidade que, em períodos de pico, se revela frequentemente insuficiente [2].

2.2 Complexidade Organizacional e Informacional

Para além da pressão demográfica, os hospitais são organizações de elevada complexidade interna. A coordenação distribuída é uma necessidade estrutural neste domínio: decisões são tomadas por múltiplos profissionais em simultâneo, frequentemente sem uma autoridade centralizada que agregue toda a informação necessária [3]. A isto acresce a criticidade temporal — atrasos na triagem, no diagnóstico ou na alocação de recursos podem ter consequências diretas na vida dos doentes [4].

Do ponto de vista da informação, os hospitais modernos geram e consomem volumes massivos de dados heterogêneos: registos clínicos eletrónicos, resultados de exames, dados de monitorização contínua provenientes de dispositivos IoT, informação administrativa de agendamento e faturação, e dados farmacológicos. Estes dados encontram-se frequentemente distribuídos por sistemas incompatíveis, dificultando uma visão integrada do estado do doente e do hospital [5].

2.3 Adequação dos Sistemas Multiagente

Estas características — heterogeneidade de atores, dinamismo, descentralização, criticidade temporal e sobrecarga informacional — tornam o domínio da saúde particularmente adequado para a aplicação de tecnologias multiagente [3]. Um SMA é capaz de modelar cada ator ou recurso como um agente autónomo que percebe o ambiente, delibera sobre as suas ações e comunica com outros agentes para coordenar comportamentos coletivos, sem necessidade de um controlador central onisciente.

Ao contrário dos sistemas centralizados, os SMA apresentam três propriedades estruturais especialmente valiosas neste contexto. Em primeiro lugar, a *tolerância a falhas*: a ausência de um ponto único de falha garante que o sistema mantém a sua capacidade operacional mesmo quando componentes individuais falham ou ficam temporariamente indisponíveis — uma propriedade crítica em ambientes hospitalares onde a continuidade de serviço é imperativa. Em segundo lugar, a *escalabilidade*: novos agentes (representando novos profissionais, equipamentos ou serviços) podem ser adicionados ao sistema sem exigir uma reestruturação global da arquitetura. Em terceiro lugar, a *adaptabilidade*: os agentes podem ajustar o seu comportamento em resposta a mudanças no ambiente — como a chegada inesperada de uma emergência ou a avaria de um equipamento —, renegociando alocações e reescalando tarefas de forma autónoma.

3 Estado da Arte

A revisão da literatura aqui apresentada foi conduzida com base em pesquisas nas bases de dados IEEE Xplore, ACM Digital Library, PubMed e Google Scholar, focando-se em publicações de 2019 ou mais recentes. Os critérios de inclusão abrangeram artigos que: (i) propõem, implementam ou avaliam sistemas baseados em agentes no contexto da saúde; (ii) descrevem a arquitetura multi-

gente utilizada; e (iii) reportam resultados experimentais ou de simulação. Foram excluídos artigos de revisão sem componente de avaliação própria e trabalhos que, embora mencionassem agentes, não adotavam uma arquitetura multiagente explícita. A revisão organiza-se pelas quatro sub-áreas de aplicação identificadas como mais relevantes, incluindo uma análise dedicada às arquiteturas e métodos de comunicação.

3.1 Triagem Clínica e Gestão de Emergências

A triagem hospitalar — processo de avaliação e priorização de doentes com base na gravidade clínica — constitui uma das aplicações mais exploradas de SMA na saúde. Os protocolos de triagem tradicionais, como o Sistema de Triagem de Manchester (MTS), são aplicados manualmente e estão sujeitos a variabilidade inter-observador e a congestionamentos em períodos de pico. A investigação recente tem explorado a integração de LLMs em arquiteturas multiagente para automatizar e melhorar este processo.

Kim et al. [6] propõem um sistema de suporte à decisão clínica baseado num SMA alimentado por LLMs, desenhado especificamente para urgências hospitalares. O sistema compreende quatro agentes especializados que simulam papéis clínicos distintos: um Agente Enfermeiro de Triagem (que avalia a gravidade do doente segundo a escala KTAS), um Agente Médico de Urgência (que elabora o plano de tratamento), um Agente Farmacêutico (que verifica interações medicamentosas via integração com a API RxNorm) e um Agente Coordenador de Urgência (que gere o fluxo global de doentes). A arquitetura utiliza o modelo Llama-3-70b como base dos agentes e demonstrou uma precisão de triagem significativamente superior à de sistemas single-agent, com uma concordância de 91% com decisões de especialistas humanos.

Feng et al. [7] desenvolvem o *TriageAgent*, um SMA heterogéneo para triagem colaborativa baseado em mecanismos de auto-confiança e *early-stopping* em discussões multi-ronda. O sistema integra uma abordagem de *Retrieval-Augmented Generation* (RAG) com o *handbook* ESI (*Emergency Severity Index*), permitindo que os agentes acedam a conhecimento de triagem estruturado durante o processo de deliberação. A arquitetura combina previsões de granularidade grossa e fina dos níveis ESI, demonstrando uma melhoria de 15% na precisão face a abordagens de agente único.

3.2 Gestão de Recursos Hospitalares

A alocação eficiente de recursos em hospitais — camas, salas de cirurgia, equipamentos e pessoal — é um problema de otimização combinatória de elevada complexidade, agravado pelo dinamismo do ambiente hospitalar. A investigação recente tem explorado abordagens que combinam SMA com técnicas de otimização avançadas.

Cincar [8] propõe um sistema multiagente para planeamento hospitalar apresentado na conferência IEEE EHB 2020. O sistema modela médicos e recursos como agentes autónomos com preferências e restrições, e utiliza um mecanismo de

negociação iterativa para determinar horários de trabalho ótimos. A otimização considera o tempo de serviço, a taxa de chegada de doentes, os tempos de espera e os tempos de conclusão, visando minimizar os custos de escalonamento. Em simulações com dados hospitalares reais, o sistema demonstrou uma redução de 22% nos custos operacionais de escalonamento face à alocação manual.

Karakra et al. [9] propõem uma arquitetura de *digital twin* baseada em agentes para a gestão de urgências hospitalares, evoluindo o conceito original do *HospiT'Win*. O sistema utiliza agentes para modelar recursos (equipamentos e pessoal) e doentes dentro do *digital twin*, sincronizando-se com o sistema de informação do departamento de urgências real. A arquitetura opera em três modos: *Digital Shadow* (monitorização em tempo real), *Digital Twin Sincronizado* (simulação preditiva do estado futuro) e *Digital Twin Exploratório* (simulação de cenários hipotéticos). Este sistema permitiu aos gestores hospitalares testar políticas de alocação de recursos sem impacto nos doentes reais, com simulações preditivas a demonstrar uma precisão de 89% na previsão de congestionamentos com 30 minutos de antecedência.

Lazebnik [10] propõe uma abordagem para o problema de alocação de pessoal e recursos hospitalares combinando simulação baseada em agentes com um agente de *deep reinforcement learning*. O sistema treina um agente DRL em dados sintéticos gerados a partir de registos reais de quatro clínicas comunitárias israelitas, aprendendo políticas de alocação ótimas que consideram restrições legais, económicas e operacionais num ambiente estocástico. Ao contrário de trabalhos anteriores que focavam um único hospital ou objetivo, a abordagem é concebida para múltiplos hospitais e objetivos simultâneos. Os resultados demonstram uma melhoria significativa na taxa de sucesso dos tratamentos face aos registos históricos de alocação manual, com o modelo a revelar maior robustez perante anomalias de admissão quando treinado com horizontes temporais curtos.

3.3 Monitorização de Doentes e IoT Médica

A monitorização contínua de doentes — seja em contexto hospitalar, de ambulatório ou domiciliário — é uma área em que os SMA encontram aplicação natural, particularmente quando integrados com dispositivos de *Internet of Things* (IoT) médica e *wearables*. A investigação recente tem focado a integração de arquiteturas multiagente com redes de sensores heterogéneas.

Saleem et al. [11] propõem um mecanismo de monitorização contínua baseado em agentes BDI (*Belief-Desire-Intention*) com consciência situacional (*situation-awareness*) para deteção precoce de sintomas de saúde através de *smartwatch*. O sistema integra dados de sensores *wearable* — frequência cardíaca, temperatura e oximetria — num formalismo de lógica temporal, onde cada agente BDI perceciona o estado fisiológico do utilizador, delibera sobre a situação clínica e desencadeia alertas personalizados sem intervenção humana. A arquitetura multiagente é validada através de um caso de estudo em NetLogo, demonstrando a escalabilidade do modelo e a sua capacidade de detetar alterações subtis nos sinais

vitais e notificar tanto o utilizador como os prestadores de cuidados de saúde em tempo real.

Dhanvijay e Patil [12] apresentam uma arquitetura IoT multi-sensor para monitorização contínua de doentes com *wearables*. O sistema integra sensores heterogéneos (ECG, EEG, temperatura, oximetria, pressão arterial) numa arquitetura em camadas: uma camada de nós sensores (comunicando via *Zigbee*, *Bluetooth* ou *Wi-Fi*), uma camada de gestão local (computadores hospitalares que executam agentes de processamento) e uma camada *cloud* para armazenamento e análise. Os agentes de cada camada comunicam de forma assíncrona, permitindo latências de alerta inferiores a 3 segundos em 97% dos eventos críticos simulados. A eficiência energética dos dispositivos *wearable* foi identificada como o principal desafio técnico.

Al-Turjman et al. [13] propõem uma arquitetura IoT inteligente para monitorização em tempo real, integrando redes neuronais otimizadas (IONN) com agentes de processamento distribuído. O sistema utiliza agentes especializados para deteção precoce de anomalias nos sinais vitais, com uma precisão de 96% em *datasets* clínicos de referência. A integração com *blockchain* para garantir a segurança e integridade dos dados médicos é uma contribuição relevante desta arquitetura, abordando preocupações de privacidade que são particularmente prementes no contexto do RGPD.

3.4 Suporte à Decisão Clínica

O suporte à decisão clínica (SDC) engloba um conjunto de tecnologias destinadas a auxiliar os profissionais de saúde na tomada de decisões baseadas em evidência, desde o diagnóstico até à seleção de tratamentos. A investigação recente combina SMA com *knowledge graphs* e LLMs para melhorar a precisão e a explicabilidade das recomendações.

Chen et al. [14] propõem o *KG4Diagnosis*, um sistema multiagente hierárquico que integra LLMs com construção automática de *knowledge graphs* médicos, abrangendo 362 doenças comuns em múltiplas especialidades clínicas. A arquitetura reproduz o funcionamento real dos sistemas de saúde através de dois níveis: um agente de clínica geral que realiza a avaliação inicial e encaminhamento, coordenando agentes especialistas que aprofundam o diagnóstico em domínios específicos. A inovação central reside na metodologia de geração de *knowledge graphs* de ponta a ponta, que incorpora extração semântica de entidades e relações otimizada para terminologia médica, reconstrução de relações de decisão multidimensionais a partir de texto clínico não estruturado, e raciocínio guiado por especialistas para expansão do conhecimento. O sistema demonstra que a combinação de arquiteturas multiagente com *knowledge graphs* estruturados melhora substancialmente a precisão e a explicabilidade do diagnóstico diferencial face a abordagens de agente único.

3.5 Arquiteturas e Métodos de Comunicação

A análise dos trabalhos revistos permite identificar padrões concretos na forma como as arquiteturas multiagente e os mecanismos de comunicação foram concretizados em cada sistema. Esta secção sistematiza essas escolhas de design a partir dos artigos estudados.

Arquiteturas Multiagente

Os trabalhos revistos evidenciam três abordagens arquiteturais distintas, cada uma motivada pelos requisitos específicos do domínio de aplicação.

Arquiteturas BDI puras. O modelo BDI (*Belief-Desire-Intention*) é adotado nos trabalhos em que o raciocínio deliberativo e a explicabilidade são prioritários. Saleem et al. [11] implementam agentes BDI com consciência situacional para processar dados de *smartwatch* (frequência cardíaca, temperatura e oximetria) através de lógica temporal, onde as crenças do agente são atualizadas continuamente por leituras dos sensores e as intenções traduzem-se em alertas automáticos ao utilizador ou ao prestador de cuidados. A escolha do BDI neste contexto justifica-se pela necessidade de raciocínio transparente sobre estados fisiológicos — o agente deve ser capaz de explicar por que razão emitiu um alerta, o que seria impossível num modelo puramente baseado em aprendizagem automática.

Arquiteturas híbridas e de simulação. Quando o problema envolve otimização de recursos em ambientes estocásticos, os trabalhos recorrem a arquiteturas que combinam agentes com técnicas de aprendizagem. Lazebnik [10] opta por uma arquitetura de simulação baseada em agentes junta a um agente de *deep reinforcement learning* (DRL): os agentes de simulação modelam o comportamento dos recursos e do fluxo de doentes, gerando dados sintéticos que treinam o agente DRL sem necessidade de interromper o funcionamento real do hospital. Esta separação entre o ambiente de simulação e o agente de decisão é uma escolha arquitetural deliberada para lidar com a escassez de dados rotulados em contexto hospitalar. Cincar [8], por outro lado, utiliza um mecanismo de negociação iterativa onde cada agente submete propostas de horário que são avaliadas por um agente coordenador segundo critérios de custo e disponibilidade — uma abordagem híbrida entre deliberação individual e coordenação centralizada.

Arquiteturas baseadas em LLMs. Os trabalhos mais recentes substituem o motor de raciocínio simbólico por um LLM, o que altera profundamente a forma como os agentes são concebidos e coordenados. Kim et al. [6] definem quatro agentes com papéis clínicos distintos, cada um instanciado sobre o modelo Llama-3-70b com um *system prompt* diferente que codifica o seu papel e responsabilidades. A coordenação é feita pelo Agente Coordenador, que agrega as saídas dos restantes agentes e determina o plano de tratamento final. Feng et al. [7] introduzem um mecanismo diferente: os agentes do *TriageAgent* debatem em múltiplas rondas, e cada agente reporta um nível de auto-confiança nas suas conclusões; o debate termina quando a confiança agregada ultrapassa um limiar

(*early-stopping*), evitando rondas redundantes. Chen et al. [14] adicionam uma camada estrutural ao modelo LLM através de *knowledge graphs* hierárquicos: um agente de clínica geral consulta o grafo de conhecimento para triagem inicial e encaminhamento, e os agentes especialistas aprofundam o diagnóstico consultando subgrafos específicos da sua área clínica.

Protocolos de Comunicação

A escolha do protocolo de comunicação está ligada à arquitetura adotada e ao tipo de coordenação necessária em cada sistema.

FIPA-Contract-Net. O protocolo mais utilizado nos trabalhos de gestão de recursos é o FIPA-Contract-Net, que estrutura a coordenação como um processo de licitação: um agente iniciador anuncia uma tarefa, os agentes participantes submetem propostas, e o iniciador escolhe candidato mais adequado. Cincar [8] implementa este protocolo na plataforma JADE para a negociação de horários médicos, onde o agente coordenador lança chamadas a concurso para cada turno disponível e avalia as propostas dos Agentes Médico com base em preferências e restrições. A formalização rigorosa do FIPA-ACL — que define atos comunicativos como *inform*, *request*, *propose*, *accept-proposal* e *reject-proposal* — torna o comportamento do sistema auditável e verificável.

Comunicação implícita via memória partilhada e RAG. Nos sistemas baseados em LLMs, a comunicação entre agentes assume uma forma diferente: em vez de troca explícita de mensagens, os agentes partilham contexto através de um histórico de conversa ou de um mecanismo de *Retrieval-Augmented Generation*. No *TriageAgent* de Feng et al. [7], os agentes acedem ao mesmo documento ESI via RAG durante o processo de deliberação, o que constitui uma forma de memória partilhada passiva. No sistema de Kim et al. [6], o Agente Coordenador atua como ponto de integração que recebe as saídas dos restantes agentes e as inclui no contexto da decisão final — uma arquitetura de comunicação em estrela, onde toda a informação converge no coordenador. No KG4Diagnosis [14], a comunicação entre os níveis hierárquicos é mediada pelo *knowledge graph*, que serve simultaneamente como canal de comunicação estruturado e como base de conhecimento partilhada.

4 Análise Crítica e Comparativa

A tabela seguinte sintetiza os principais trabalhos analisados:

Table 1. Comparação dos trabalhos revistos

Trabalho	Domínio	Arquitetura	Plataforma/ Protocolo	Vantagens	Limitações
Kim et al. (2024)	Triagem clínica	LLM-based (4 agentes)	Llama-3-70b / Custom	Concordância 91% com especialistas	Dependência do LLM base
Feng et al. (2024)	Triagem clínica	LLM + RAG + early-stopping	Custom / ESI handbook	+15% precisão vs. agente único	Complexidade do pipeline
Cincar (2020)	Planeamento hospitalar	Híbrida + Contract-Net	JADE / FIPA-ACL	−22% custos de escalonamento	Escalabilidade limitada
Karakra et al. (2019)	Digital twin urgências	Agentes + 3 modos DT	Custom / simulação discreta	Predição 89% congestionamentos a 30 min	Integração com SI hospitalares
Lazebnik (2023)	Escalonamento recursos	ABS + DRL	Custom / simulação	Generalização a múltiplos hospitais	Treino intensivo, dados sintéticos
Saleem et al. (2022)	Monitorização wearable	BDI + lógica temporal	NetLogo	Alertas em tempo real	Validação por simulação
Dhanvijay & Patil (2021)	Monitorização IoT	Multi-camada IoT	Custom / Zigbee + Wi-Fi	Latência <3s em 97% alertas	Consumo energético dos wearables
Al-Turjman et al. (2022)	Monitorização IoT	IONN + Blockchain	Custom	96% precisão	Overhead da blockchain, complexidade
Chen et al. (2024)	Diagnóstico diferencial	LLM + KG hierárquico	Custom / KG médico	362 doenças, explicabilidade	Custo de manutenção

4.1 Convergências e Divergências entre os Trabalhos

A leitura cruzada dos nove trabalhos revistos permite identificar convergências metodológicas relevantes, mas também divergências que refletem as especificidades de cada domínio de aplicação.

Triagem clínica: Kim et al. [6] e Feng et al. [7] abordam o mesmo problema — automatização da triagem em urgências — com estratégias distintas. Kim et al. optam por uma divisão rígida de papéis (quatro agentes com funções fixas e bem delimitadas), privilegiando a fidelidade ao processo clínico real e a integração com sistemas externos como a API RxNorm para verificação de medicamentos. Feng et al. apostam numa arquitetura mais dinâmica, onde os agentes debatem livremente e um mecanismo de auto-confiança controla a convergência. O resultado é que o

sistema de Kim et al. é mais interpretável do ponto de vista clínico (cada agente corresponde a um papel reconhecível pelos profissionais de saúde), enquanto o *TriageAgent* de Feng et al. é mais flexível e menos dependente de uma estrutura organizacional pré-definida.

Gestão de recursos: Cincar [8] e Lazebnik [10] representam duas gerações de abordagens ao escalonamento de recursos. Cincar utiliza o FIPA-Contract-Net, uma solução madura e auditável mas que, por assentar em preferências estáticas dos agentes, não se adapta facilmente a variações imprevistas na procura. Lazebnik abandona a negociação explícita entre agentes e substitui-a por um agente DRL que aprende políticas de alocação a partir de simulação, ganhando adaptabilidade mas perdendo a explicabilidade que o FIPA-ACL proporcionava.

Monitorização: Os três trabalhos de monitorização — Saleem et al. [11], Dhanvijay e Patil [12], e Al-Turjman et al. [13] — partilham o objetivo de detetar eventos clínicos críticos a partir de dados de sensores, mas diferem significativamente nas escolhas de design. Saleem et al. centram-se no raciocínio simbólico (BDI + lógica temporal) sobre um conjunto limitado de sinais vitais, com ênfase na explicabilidade dos alertas. Dhanvijay e Patil focam-se na arquitetura de comunicação entre camadas e na latência de ponta a ponta, obtendo os resultados mais concretos em termos de desempenho temporal (<3 segundos em 97% dos alertas). Al-Turjman et al. acrescentam uma dimensão de segurança e privacidade via *blockchain*, abordando explicitamente as implicações do RGPD.

Suporte à decisão: Chen et al. [14] oferecem a abordagem mais recente e abrangente ao diagnóstico diferencial multiagente, combinando LLMs com *knowledge graphs* gerados automaticamente. A distinção face a sistemas anteriores reside na escala (362 doenças) e na metodologia de construção do KG, que é induzida a partir de texto clínico não estruturado.

4.2 Análise das Limitações Metodológicas

Para além das limitações específicas de cada sistema, é possível identificar três limitações transversais que afetam a maioria dos trabalhos revistos e condicionam a comparabilidade dos resultados.

A primeira é a **ausência de validação prospetiva**. Dos nove trabalhos, apenas Cincar [8] reporta resultados com dados hospitalares reais (ainda que históricos); os restantes baseiam-se em simulação, datasets retrospectivos ou benchmarks sintéticos. Esta lacuna é particularmente problemática em contexto clínico, onde o desempenho em simulação raramente se traduz diretamente para o ambiente real [3].

A segunda limitação é a **incomensurabilidade das métricas de avaliação**. Os trabalhos utilizam métricas heterogêneas — precisão de triagem (Kim et al., Feng et al.), redução percentual de custos (Cincar), taxa de sucesso de tratamento (Lazebnik), latência de alerta (Dhanvijay e Patil) — que não são diretamente comparáveis entre si. Esta heterogeneidade dificulta a identificação da abordagem mais eficaz para um dado domínio e evidencia a ausência de benchmarks padronizados para SMA em saúde.

A terceira é a **omissão de requisitos regulatórios**. Com exceção de Al-Turjman et al. [13], que abordam explicitamente a privacidade de dados no contexto do RGPD, e de Chen et al. [14], que discutem a explicabilidade das decisões, nenhum dos trabalhos considera os requisitos do *AI Act* europeu — que classifica os sistemas de IA em saúde como de alto risco e exige auditabilidade, transparência e supervisão humana. Esta omissão é especialmente relevante para os sistemas baseados em LLMs, cujo comportamento é inerentemente não determinístico.

5 Tendências Futuras

A investigação em SMA aplicados à saúde encontra-se num momento de particular dinamismo, impulsionado pela convergência com outras tecnologias emergentes e por novos desafios regulatórios e sociais. Esta secção identifica as tendências com maior potencial de impacto nos próximos anos.

Integração com LLMs e IA Generativa Os *Large Language Models* (LLMs) demonstram capacidades notáveis de raciocínio clínico, síntese de informação e interação em linguagem natural [15]. A sua integração como componente deliberativa de agentes BDI — uma arquitetura designada de *LLM-based agents* — representa uma das tendências mais promissoras, permitindo que os agentes compreendam instruções clínicas em linguagem natural e gerem explicações das suas decisões acessíveis a profissionais de saúde. Os trabalhos de Kim et al. [6] e Feng et al. [7] já demonstram a viabilidade desta abordagem em triagem clínica, enquanto a extensão SPADE-LLM [16] oferece uma plataforma de desenvolvimento para sistemas multiagente baseados em LLMs. Esta integração aborda diretamente a lacuna de explicabilidade identificada na literatura, um requisito crescente no contexto do *AI Act* europeu.

Digital Twins Hospitalares A criação de réplicas virtuais dinâmicas de hospitais ou unidades clínicas, alimentadas por dados em tempo real, permitirá simular o impacto de decisões de gestão antes da sua implementação [9]. Os SMA são o paradigma natural para povoar estes digital twins com agentes que replicam o comportamento de doentes, profissionais e recursos. O trabalho de Fontanili et al. demonstra a viabilidade desta abordagem com três modos de operação (*monitoring, predictive, exploratory*), permitindo testar políticas de triagem ou alocação de recursos sem risco para os doentes reais.

Telemedicina e Cuidados Domiciliários A pandemia de COVID-19 acelerou significativamente a adoção de modelos de cuidado remoto, tornando a telemedicina uma componente estrutural dos sistemas de saúde modernos. Os SMA têm um papel crescente na orquestração de plataformas de telemedicina, na monitor-

ização proativa de doentes em casa — através da integração com dispositivos IoT e *wearables* [12, 13] — e na coordenação entre prestadores de cuidados primários e especialistas hospitalares. A capacidade dos agentes de monitorizar continuamente o estado do doente e escalar alertas de forma autónoma torna-os particularmente adequados a este modelo de cuidados distribuídos.

Questões Éticas e Regulatórias A adoção de sistemas autónomos em contexto clínico coloca desafios éticos e regulatórios que a investigação em SMA não pode ignorar. O Regulamento Geral de Proteção de Dados (RGPD) impõe restrições ao processamento de dados de saúde; o *AI Act* da União Europeia classifica os sistemas de IA em saúde como de alto risco, sujeitos a requisitos de auditabilidade, transparência e supervisão humana [17]. A investigação futura deverá incorporar explicitamente estes requisitos no design dos sistemas, nomeadamente através de mecanismos de explicação das decisões dos agentes (*Explainable AI*) e de arquiteturas que garantam a supervisão humana em decisões críticas.

Aprendizagem e Adaptação Contínua Uma limitação recorrente nos sistemas SMA revistos é a dependência de modelos estáticos de conhecimento. A integração de técnicas de aprendizagem por reforço [10] e aprendizagem federada permitirá que os agentes adaptem o seu comportamento com base na experiência acumulada, sem comprometer a privacidade dos dados dos doentes. Esta tendência é particularmente relevante em domínios como o suporte à decisão clínica, onde as evidências médicas evoluem continuamente.

6 Proposta de Implementação

Com base na revisão do estado da arte apresentada, esta secção descreve uma proposta conceptual de um Sistema Multiagente para gestão hospitalar integrada. A proposta tem carácter exploratório e procura estabelecer o cenário e a arquitetura de referência para desenvolvimento futuro, não constituindo uma implementação definitiva.

6.1 Cenário e Âmbito

O cenário proposto consiste num sistema de gestão hospitalar centrado, numa fase inicial, no serviço de Pediatria. A escolha desta especialidade justifica-se por três razões: os fluxos de cuidados são bem definidos e protocolizados; a criticidade temporal é elevada, dado que crianças podem deteriorar clinicamente com rapidez; e a dimensão do serviço é suficientemente contida para validar o modelo antes de uma expansão a outras especialidades. A arquitetura foi pensada de forma modular, permitindo que cada especialidade adicional seja integrada sem alterações estruturais ao sistema.

O sistema tem como objetivo coordenar de forma autónoma e descentralizada quatro domínios funcionais interdependentes: marcação e gestão de consultas, requisição e agendamento de exames médicos, planeamento de cirurgias e gestão de internamentos. A interdependência entre estes domínios — uma consulta pode gerar um exame, que pode gerar uma cirurgia, que determina um internamento — é precisamente o tipo de problema para o qual os SMA oferecem vantagens face a sistemas centralizados, pela sua capacidade de propagar e renegociar alocações em cascata.

6.2 Arquitetura Multiagente Proposta

A arquitetura proposta organiza-se em três camadas: agentes de recursos, agentes coordenadores e um agente supervisor. A plataforma de desenvolvimento selecionada é o SPADE, que oferece suporte nativo a comunicação assíncrona entre agentes via XMPP e integração simplificada com sistemas externos através de Python. A escolha do SPADE é informada pela análise das plataformas realizada na Secção 3.5, privilegiando a modernidade do ecossistema Python, a escalabilidade do XMPP e a disponibilidade da extensão SPADE-LLM para futura integração de grandes modelos de linguagem.

Agentes de Recursos

Os agentes de recursos representam as entidades físicas e humanas do hospital:

- **Agente Doente:** representa o processo clínico de cada doente. Mantém o registo de consultas, exames e procedimentos pendentes, e emite pedidos ao sistema sempre que é necessário agendar uma nova interação clínica. Incorpora um nível de prioridade que reflete a urgência clínica do doente, atualizado dinamicamente pelo Agente Supervisor;
- **Agente Médico:** representa cada profissional de saúde. Gere a sua disponibilidade horária, especialidade e capacidade de resposta, aceitando ou recusando propostas de alocação com base nas suas restrições e preferências;
- **Agente Sala/Equipamento:** representa os recursos físicos do hospital — salas de consulta, salas cirúrgicas, blocos operatórios e equipamentos de diagnóstico (como ecógrafos, equipamentos de imagiologia ou laboratórios). Gere a disponibilidade temporal de cada recurso e sinaliza conflitos de alocação.

Agentes Coordenadores

Os agentes coordenadores são responsáveis pela negociação e alocação de recursos em cada domínio funcional, utilizando o protocolo *FIPA-Contract-Net* como mecanismo de base. Cada pedido de alocação é tratado como um contrato: o coordenador anuncia a tarefa, os agentes de recursos elegíveis submetem propostas, e o coordenador adjudica ao candidato que melhor satisfaz os critérios de otimização (disponibilidade, proximidade temporal, especialidade adequada):

- **Agente Coordenador de Consultas:** medeia o agendamento de consultas, encontrando o melhor conjunto disponível de médico, sala e horário para cada

pedido. Considera a prioridade clínica do doente na ordenação dos pedidos em fila;

- **Agente Coordenador de Exames:** gere a requisição e agendamento de exames médicos, incluindo a dependência temporal face à consulta que os originou. Coordena a disponibilidade do equipamento necessário e do técnico ou médico responsável;
- **Agente Coordenador de Cirurgias e Internamentos:** trata a cadeia mais complexa do sistema, coordenando a alocação simultânea de bloco operatório, cirurgião, anestesista e cama de internamento pós-operatório. Gere igualmente os processos de alta e libertação de camas.

Agente Supervisor

O Agente Supervisor constitui a componente de gestão global do sistema. As suas responsabilidades principais são: monitorizar continuamente o estado de todos os recursos e filas de espera; detetar situações de congestionamento ou conflito; e, em caso de emergência clínica, desencadear um mecanismo de reescalonamento dinâmico.

Quando uma emergência é registada, o Supervisor eleva a prioridade do Agente Doente correspondente e notifica os coordenadores relevantes, que iniciam um novo ciclo de negociação *Contract-Net* com prioridades atualizadas. Alocações previamente feitas a doentes de menor prioridade podem ser temporariamente suspensas e renegociadas, libertando recursos para o caso urgente. Este mecanismo de interrupção e reescalonamento em cascata distingue-se de uma simples fila de prioridades por ser reativo ao estado real do sistema, não apenas à ordem de chegada dos pedidos.

6.3 Fluxo de Interação Típico

A título ilustrativo, o fluxo de interação para uma consulta que origina um exame decorre da seguinte forma: o Agente Doente emite um pedido de consulta ao Agente Coordenador de Consultas; este lança um *Contract-Net* junto dos Agentes Médico e Agentes Sala disponíveis; após adjudicação, a consulta é agendada e o Agente Doente é notificado. Se durante a consulta o médico requisitar um exame, o Agente Médico notifica o Agente Coordenador de Exames com os requisitos clínicos e a janela temporal pretendida; o coordenador inicia um novo *Contract-Net* junto dos Agentes Sala/Equipamento adequados, garantindo que o exame é agendado após a consulta e dentro do prazo clinicamente indicado.

7 Conclusão

Esta revisão demonstrou que os Sistemas Multiagente constituem um paradigma maduro e em acelerada transformação, cuja adequação estrutural aos desafios dos sistemas de saúde modernos se tem vindo a confirmar. A análise de trabalhos revela uma transição significativa: das arquiteturas BDI e dos protocolos FIPA

sobre plataformas como JADE, para sistemas que integram *Large Language Models*, *deep reinforcement learning* e mecanismos de *Retrieval-Augmented Generation*. Esta evolução não é apenas tecnológica — reflete uma mudança na forma como se concebe a autonomia dos agentes, que passam de entidades com raciocínio simbólico explícito para entidades com compreensão semântica de contexto clínico.

Os resultados quantitativos reportados — reduções de 22 a 30% em tempos de espera, concordâncias de 91% com especialistas em triagem, latências de alerta inferiores a 3 segundos — são encorajadores, mas devem ser interpretados com cautela: a maioria dos sistemas foi validada exclusivamente em ambientes de simulação ou sobre datasets retrospectivos. Esta lacuna entre a promessa demonstrada e a validação clínica real constitui, talvez, o desafio mais urgente da área. Enquanto os estudos continuarem a basear-se em cenários controlados, a adoção institucional permanecerá condicionada pela incerteza sobre o comportamento dos sistemas em produção.

A par desta limitação, destaca outros dois obstáculos estruturais. A ausência de *benchmarks* padronizados, que tornam a comparação de abordagens metodologicamente problemática e dificultam a reutilização de soluções entre instituições. A omissão quase generalizada dos requisitos regulatórios europeus — nomeadamente o *AI Act*, que classifica os sistemas de IA em saúde como de alto risco —, uma lacuna que se tornará cada vez mais difícil de ignorar à medida que estes sistemas avançam para contextos clínicos reais.

Ainda assim, as tendências futuras identificadas apontam para caminhos concretos de superação destas limitações: a integração de LLMs em arquiteturas BDI promete conciliar explicabilidade e compreensão semântica; os *digital twins* hospitalares abrem a possibilidade de validação realista sem risco para os doentes; e a aprendizagem federada oferece uma via para a adaptação contínua dos sistemas sem comprometer a privacidade dos dados.

O trabalho futuro desta investigação focar-se-á no desenvolvimento e validação do protótipo descrito na Secção 6, iniciando-se no serviço de Pediatria com a plataforma SPADE. Esse será o contributo que esta linha de investigação procura trazer a um campo que, tendo demonstrado a sua viabilidade teórica, aguarda confirmação prática.

References

1. OECD/European Commission: Health at a Glance: Europe 2024. OECD Publishing, Paris (2024). <https://doi.org/10.1787/b3704e14-en>.
2. Eurostat: Healthcare Resource Statistics – Beds, https://ec.europa.eu/eurostat/statistics-explained/index.php/Healthcare_resource_statistics_-_beds.
3. Isern, D., Moreno, A.: Systematic Review of Multi-Agent Systems Applied to Clinical Settings: Challenges and Opportunities. *Journal of Medical Systems*. 40, 43 (2016). <https://doi.org/10.1007/s10916-015-0376-2>.
4. Ben Khalfallah, M., Jarrar, R., Cherif, A., Nicolle, C.: Decision Support Systems in Healthcare: Systematic Review, Meta-Analysis and Prediction. *AIMS Bioengineering*. 10, 1–18 (2023). <https://doi.org/10.3934/bioeng.2023004>.

5. Habebhh, H., Gohel, S.: Machine Learning in Healthcare. *Current Genomics*. 22, 291–300 (2021). <https://doi.org/10.2174/1389202922666210705124359>.
6. Han, S., Choi, W.: Development of a Large Language Model-based Multi-Agent Clinical Decision Support System for Korean Triage and Acuity Scale (KTAS)-Based Triage and Treatment Planning in Emergency Departments, <https://arxiv.org/abs/2408.07531>.
7. Lu, M., Ho, B., Ren, D., Wang, X.: TriageAgent: Towards Better Multi-Agents Collaborations for Large Language Model-Based Clinical Triage. In: *Findings of the Association for Computational Linguistics: EMNLP 2024*. pp. 5747–5764 (2024). <https://doi.org/10.18653/v1/2024.findings-emnlp.329>.
8. Cincar: Hospital Management and Scheduling with Multi Agents Approach. In: *2020 International Conference on e-Health and Bioengineering (EHB)*. IEEE (2020). <https://doi.org/10.1109/EHB50910.2020.9280281>.
9. Karakra, A., Fontanili, F., Lamine, E., Lamothe, J.: HospiT'Win: A Predictive Simulation-Based Digital Twin for Patients Pathways in Hospital. In: *2019 IEEE EMBS International Conference on Biomedical & Health Informatics (BHI)*. pp. 1–4. IEEE (2019). <https://doi.org/10.1109/BHI.2019.8834534>.
10. Lazebnik, T.: Data-Driven Hospital Staff and Resources Allocation Using Agent-Based Simulation and Deep Reinforcement Learning. *Engineering Applications of Artificial Intelligence*. 124, 106783 (2023). <https://doi.org/10.1016/j.engappai.2023.106783>.
11. Saleem, K., Saleem, M., Ahmad, R.Z., Javed, A.R., Alazab, M., Gadekallu, T.R., Suleman, A.: Situation-Aware BDI Reasoning to Detect Early Symptoms of Covid-19 Using Smartwatch. *IEEE Sensors Journal*. 23, 898–905 (2022). <https://doi.org/10.1109/JSEN.2022.3156819>.
12. Dhanvijay, M.M., Patil, S.C.: Internet of Things: A Survey of Enabling Technologies in Healthcare and Its Applications. *Computer Networks*. 153, 113–131 (2019). <https://doi.org/10.1016/j.comnet.2019.03.006>.
13. Al-Turjman, F., Nawaz, M.H., Ulusar, U.D.: Intelligence in the Internet of Medical Things Era: A Systematic Review of Current and Future Trends. *Computer Communications*. 150, 614–660 (2019). <https://doi.org/10.1016/j.comcom.2019.12.030>.
14. Chen, X., Liu, Y., Huang, X., Xu, W., Zhang, Y., Chen, Y., Wang, Y.: KG4Diagnosis: A Hierarchical Multi-Agent LLM Framework with Knowledge Graph Enhancement for Medical Diagnosis, <https://arxiv.org/abs/2412.16833>.
15. Singhal, K., Azizi, S., Tu, T., others: Large Language Models Encode Clinical Knowledge. *Nature*. 620, 172–180 (2023). <https://doi.org/10.1038/s41586-023-06291-2>.
16. Palanca, J., Rincon, J.A., Carrascosa, C., Julian, V., Terrasa, A.: A Flexible Agent Architecture in SPADE. In: *Advances in Practical Applications of Agents, Multi-Agent Systems, and Complex Systems Simulation. The PAAMS Collection*. pp. 320–331. Springer (2022). https://doi.org/10.1007/978-3-031-18192-4_26.
17. European Commission: Proposal for a Regulation of the European Parliament and of the Council Laying Down Harmonised Rules on Artificial Intelligence (Artificial Intelligence Act). (2021).